Lista 2 - Mineração

Victor Alves Dogo Martins, RA: 744878 Ana Beatriz Alves Monteiro, RA: 727838 Larissa Torres, RA: 631914

17-07-2022


Item 1

```
# ITEM 1
set.seed(727838)
library(tidyverse)
library(rsample)
library(glmnet)
library(ggrepel)
library(forcats)
library(knitr)
library(kableExtra)
df <- ISLR::Carseats</pre>
df$US <- as.factor(df$US)</pre>
df$Urban <- as.factor(df$Urban)</pre>
df$ShelveLoc <- as.factor(df$ShelveLoc)</pre>
# Divisao treino e teste
split <- initial_split(df, prop=0.6)</pre>
tre <- training(split)</pre>
tes <- testing(split)</pre>
x_tre <- model.matrix(Sales~., tre)</pre>
y_tre <- tre[,1]</pre>
x_tes <- model.matrix(Sales~., tes)</pre>
y_tes <- tes[,1]</pre>
```

```
# ITEM 2
```

```
## Ajuste Minimos Quadrados
ajuste_mq <- glmnet(x_tre, y_tre, alpha=0, lambda=0)</pre>
## Ajuste Lasso
cv_lasso <- cv.glmnet(x_tre, y_tre, alpha=1)</pre>
ajuste_lasso <- glmnet(x_tre, y_tre, alpha=1, lambda = cv_lasso$lambda.1se)
## Erro x Lambda Lasso
tibble(
  lambda=cv_lasso$lambda,
 risco=cv_lasso$cvm
) |>
  ggplot()+
  aes(x=lambda, y=risco)+
  geom_line()+
  geom_vline(xintercept = cv_lasso$lambda.1se)+
  annotate(geom = 'text', y=5, x=0.25,
           label=paste0('lambda = ', round(ajuste_lasso$lambda,5)))+
  theme_minimal()+
  labs(title='Risco x Lambda estimado',
       subtitle = 'com Lambda escolhido')
```


Risco x Lambda estimado



```
## Apresentando melhor lambda (cv_lasso$lambda.1se)
lambdas <- cv_lasso$glmnet.fit$lambda
lam <- lambdas |>
```

```
as.data.frame() |>
  mutate(penalty=names(cv_lasso$glmnet.fit$a0)) %>%
  rename(lambda=1)
results <- cv_lasso$glmnet.fit$beta |>
  as.matrix() |>
  as.data.frame() |>
  rownames to column() |>
  gather(penalty,coefficients,-rowname) |>
  left_join(lam)
result_labels <- results |>
  group_by(rowname) |>
  filter(lambda==ajuste_lasso$lambda) |>
  ungroup()
ggplot()+
  geom_line(data=results, aes(lambda, coefficients,
                              group=rowname, color=rowname),
            show.legend = FALSE)+
  scale_x_log10()+
  geom_text(data=result_labels, aes(0.01, coefficients,
                                    label=rowname, color=rowname),
            nudge_x=-.06, show.legend = FALSE)+
  geom_vline(xintercept = ajuste_lasso$lambda)+
  annotate(geom = 'text', y=0.4, x=0.16,
           label=paste0('lambda = ', round(ajuste_lasso$lambda,5)))+
  theme_minimal()+
  labs(y='estimativa',
       title='Lambda x Estimativas dos Coeficientes')
```

Lambda x Estimativas dos Coeficientes




```
# ITEM 3
coef_mq <- coefficients(ajuste_mq) |>
  round(3)
coef_lasso <- coefficients(ajuste_lasso) |>
  round(3)
## Apresentando coeficientes
tibble(
  var=names(coef_mq[,1]),
  mq=coef_mq[,1],
 lasso=coef_lasso[,1]
) |> slice(-2) |>
  kable('latex', align='ccc',
        caption = 'Estimativas de Coeficientes para Mínimos Quadrados e Lasso',
        col.names=c('Variável', 'Mínimos Quadrados', 'Lasso')) |>
  kable_styling(position="center",
                latex_options="HOLD_position")
```

Table 1: Estimativas de Coeficientes para Mínimos Quadrados e Lasso


Variável	Mínimos Quadrados	Lasso
(Intercept)	6.018	6.672
CompPrice	0.093	0.080
Income	0.014	0.012
Advertising	0.119	0.110
Population	0.000	0.000
Price	-0.098	-0.089
ShelveLocGood	4.741	4.339
ShelveLocMedium	1.970	1.636
Age	-0.047	-0.042
Education	-0.032	-0.008
UrbanYes	0.230	0.033
USYes	0.089	0.021

```
geom_bar(stat='identity', show.legend = FALSE)+
theme_minimal()+
labs(x='Estimativa', y='',
    title='Estimativas do Ajuste de Mínimos Quadrados')
```

Estimativas do Ajuste de Mínimos Quadrados



Estimativas do Ajuste Lasso



```
# ITEM 4
funcao_risco <- function(y_pred, y_obs){</pre>
  w <- (y_pred-y_obs)^2</pre>
  sigma <- var(w)</pre>
  risco <- mean(w)
  liminf <- risco - (2*sqrt((1/length(w))*sigma))</pre>
  limsup <- risco + (2*sqrt((1/length(w))*sigma))</pre>
  return(tibble(risco, liminf, limsup))
}
y_pred_mq <- predict(ajuste_mq, x_tes)</pre>
y_pred_lasso <- predict(ajuste_lasso, x_tes)</pre>
risco_mq <- funcao_risco(y_pred_mq, y_tes)</pre>
risco_lasso <- funcao_risco(y_pred_lasso, y_tes)</pre>
tibble(
  Estimativa=c('Risco', 'Limite Inferior', 'Limite Superior'),
  `Minimos Quadrados`=unlist(c(risco_mq)),
  `Lasso`=unlist(c(risco_lasso))
  kable('latex', align='ccc',
        caption = 'Risco e Intervalos de Confiança para Lasso e Mínimos Quadrados',
        col.names=c('Variável', 'Mínimos Quadrados', 'Lasso')) |>
```


Table 2: Risco e Intervalos de Confiança para Lasso e Mínimos Quadrados

Variável	Mínimos Quadrados	Lasso
Risco	1.1815323	1.1869124
Limite Inferior	0.9231082	0.9441733
Limite Superior	1.4399564	1.4296515

```
# ITEM 5
x_tre2 <- model.matrix(Sales~.^2, tre)</pre>
x_tes2 <- model.matrix(Sales~.^2, tes)</pre>
## Realizando ajuste para todas as variáveis
## Ajuste Minimos Quadrados
ajuste_mq2 <- glmnet(x_tre2, y_tre, alpha=0, lambda=0)</pre>
## Ajuste Lasso
cv_lasso2 <- cv.glmnet(x_tre2, y_tre, alpha=1)</pre>
ajuste_lasso2 <- glmnet(x_tre2, y_tre, alpha=1, lambda = cv_lasso2$lambda.1se)
## Erro x Lambda Lasso
tibble(
 lambda=cv_lasso2$lambda,
  risco=cv_lasso2$cvm
) |>
  ggplot()+
  aes(x=lambda, y=risco)+
  geom_line()+
  geom_vline(xintercept = cv_lasso2$lambda.1se)+
  annotate(geom = 'text', y=5, x=0.25,
           label=paste0('lambda = ', round(ajuste_lasso2$lambda,5)))+
  theme_minimal()+
  labs(title='Risco x Lambda estimado',
       subtitle = 'com Lambda escolhido e considerando todas as interações')
```


Risco x Lambda estimado

com Lambda escolhido e considerando todas as interações



```
## Apresentando melhor lambda (cv_lasso$lambda.1se)
lambdas <- cv_lasso2$glmnet.fit$lambda</pre>
lam <- lambdas |>
  as.data.frame() |>
  mutate(penalty=names(cv_lasso2$glmnet.fit$a0)) %>%
  rename(lambda=1)
results <- cv_lasso2$glmnet.fit$beta |>
  as.matrix() |>
  as.data.frame() |>
  rownames to column() |>
  gather(penalty,coefficients,-rowname) |>
  left_join(lam)
result_labels <- results |>
  group_by(rowname) |>
  filter(lambda==ajuste_lasso2$lambda) |>
  ungroup()
ggplot()+
  geom_line(data=results, aes(lambda, coefficients,
                              group=rowname, color=rowname), show.legend = FALSE)+
  scale_x_log10()+
  geom_text(data=result_labels, aes(0.01, coefficients,
                                    label=rowname, color=rowname),
            nudge_x=-.06, show.legend = FALSE)+
  geom_vline(xintercept = ajuste_lasso2$lambda)+
  annotate(geom = 'text', y=0.4, x=0.16,
           label=paste0('lambda = ', round(ajuste_lasso2$lambda,5)))+
```

Lambda x Estimativas dos Coeficientes considerando todas as interações



```
## Apresentando coeficientes
coef_mq2 <- coefficients(ajuste_mq2) |>
  round(3)
coef_mq2 <- coef_mq2[,1]</pre>
coef_mq3 \leftarrow coef_mq2[abs(coef_mq2)>=0.01]
coef_lasso2 <- coefficients(ajuste_lasso2) |>
  round(3)
coef_lasso2 <- coef_lasso2[,1]</pre>
coef_lasso3 <- coef_lasso2[abs(coef_lasso2)>=0.01]
tibble(
  var=names(coef_mq2),
  mq=coef_mq2,
  lasso=coef_lasso2
) |> slice(-2) |>
  kable('latex', align='ccc',
        caption = 'Coeficientes para Mínimos Quadrados e Lasso com todas as interações',
        col.names=c('Variável', 'Mínimos Quadrados', 'Lasso')) |>
  kable_styling(position="center",
                 latex_options="HOLD_position")
```

Table 3: Coeficientes para Mínimos Quadrados e Lasso com todas as interações

. Coefficientes para minimos Qua	diados o Lasso com to	100 00 1110
Variável	Mínimos Quadrados	Lasso
(Intercept)	0.407	7.316
CompPrice	0.149	0.074
Income	0.071	0.000
Advertising	0.148	0.000
Population	0.003	0.000
Price	-0.086	-0.078
ShelveLocGood	4.771	1.575
ShelveLocMedium	0.789	0.000
Age	-0.071	-0.027
Education	-0.052	0.000
UrbanYes	-0.355	0.000
USYes	1.494	0.000
CompPrice:Income	0.000	0.000
CompPrice:Advertising	-0.002	0.000
CompPrice:Population	0.000	0.000
CompPrice:Price	0.000	0.000
CompPrice:ShelveLocGood	-0.004	0.017
CompPrice:ShelveLocMedium	0.004	0.007
CompPrice:Age	0.000	0.000
CompPrice:Education	-0.001	0.000
CompPrice:UrbanYes	0.006	0.000
CompPrice:USYes	0.012	0.000
Income: Advertising	0.001	0.001
Income:Population	0.000	0.000
Income:Price	0.000	0.000
Income:ShelveLocGood	-0.008	0.000
Income:ShelveLocMedium	0.009	0.009
Income:Age	0.000	0.000
Income:Education	0.000	0.000
Income:UrbanYes	0.002	0.000
Income:USYes	-0.002	0.000
Advertising:Population	0.000	0.000
Advertising:Price	0.002	0.000
Advertising:ShelveLocGood	-0.006	0.000
Advertising:ShelveLocMedium	-0.006	0.000
Advertising:Age	0.003	0.000
Advertising:Education	-0.011	0.000
Advertising:UrbanYes	-0.039	0.001
Advertising:USYes	-0.120	0.000
Population:Price	0.000	0.000
Population:ShelveLocGood	-0.001	0.000
Population:ShelveLocMedium	-0.002	0.000
Population:Age	0.000	0.000
Population:Education	0.000	0.000
Population:UrbanYes	0.000	0.000
Population:USYes	0.001	0.000
Price:ShelveLocGood	0.003	0.000
Price:ShelveLocMedium	-0.001	0.000
Price:Age	0.000	0.000
Price:Education	0.000	0.000
Price:UrbanYes	-0.009	0.000
Price:USYes 10		0.000
ShelveLocGood:Age	0.011	0.000
ShelveLocMedium:Age	0.004	0.000
Cl. 1 I C. 1 E 1	0.001	0.000


-0.005

0.000


ShelveLocGood:Education

```
## Graficos dos coeficientes de minimos quadrados
tibble(
 var=names(coef_mq3),
 val=coef_mq3
) |>
  mutate(sinal=ifelse(val<0, 'negativo', 'positivo'),</pre>
         var=fct_reorder(var, val)) |>
  arrange(val) |>
  filter(var!='(Intercept)') |>
  ggplot()+
  aes(x=val, y=var, fill=sinal)+
  geom_bar(stat='identity', show.legend = FALSE)+
  theme_minimal()+
  labs(x='Estimativa', y='',
       title='Estimativas do Ajuste de Mínimos Quadrados',
       subtitle='considerando todas as interações')
```

Estimativas do Ajuste de Mínimos Quadrados considerando todas as interações



Estimativas do Ajuste Lasso considerando todas as interações



Calculando risco estimado

Table 4: Risco e Intervalos de Confiança considerando todas as interações

Variável	Mínimos Quadrados	Lasso
Risco	1.575369	1.2080729
Limite Inferior	1.257929	0.9333602
Limite Superior	1.892809	1.4827856